

机器学习实验指导手册

贝叶斯学习

一、实验目的

- 掌握贝叶斯定理的数学原理及其在机器学习中的应用
- 理解朴素贝叶斯分类器的建模过程与假设条件
- 学会使用scikit-learn实现高斯朴素贝叶斯与多项式朴素贝叶斯模型
- 掌握文本分类任务的完整流程与评估方法
- 分析特征独立性假设对模型性能的影响

二、实验原理

1. 贝叶斯定理

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

其中：

- Y 为类别标签， X 为特征向量
- $P(Y|X)$ 为后验概率， $P(X|Y)$ 为似然度

2. 朴素贝叶斯分类器

核心假设：特征条件独立性

$$P(X|Y) = \prod_{i=1}^n P(x_i|Y)$$

分类决策：

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y)$$

3. 高斯朴素贝叶斯 (Gaussian Naive Bayes)

- 适用场景：**连续特征数据（如温度、长度等）
- 数学原理：**假设每个特征 X_i 服从高斯分布

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_i - \mu_y)^2}{2\sigma_y^2}\right)$$

```
from sklearn.naive_bayes import GaussianNB
model = GaussianNB()
model.fit(X_train, y_train)
```

4. 多项式朴素贝叶斯 (Multinomial Naive Bayes)

- **适用场景：**离散特征数据（如文本词频、文档计数）
- **数学原理：**基于多项式分布估计条件概率

$$P(x_i|y) = \frac{N_{yi} + \alpha}{N_y + \alpha n}$$

```
from sklearn.naive_bayes import MultinomialNB
model = MultinomialNB(alpha=1.0)
model.fit(X_train, y_train)
```

5. TF-IDF原理与计算

TF-IDF (Term Frequency-Inverse Document Frequency) 用于衡量词语在文档中的重要程度。

1. 词频 (Term Frequency, TF):

$$TF(t, d) = \frac{\text{词}t\text{在文档}d\text{中的出现次数}}{\text{文档}d\text{的总词数}}$$

2. 逆文档频率 (Inverse Document Frequency, IDF):

$$IDF(t) = \log\left(\frac{\text{总文档数}}{\text{包含词}t\text{的文档数} + 1}\right)$$

3. TF-IDF值:

$$TF-IDF(t, d) = TF(t, d) \times IDF(t)$$

```
from sklearn.feature_extraction.text import TfidfVectorizer
vectorizer = TfidfVectorizer(max_features=1000)
X_tfidf = vectorizer.fit_transform(X)
```

三、实验步骤

1. 高斯朴素贝叶斯实验 (数值数据)

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split

# 加载数据
X, y = load_iris(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)

# 训练模型
model = GaussianNB()
model.fit(X_train, y_train)

# 评估
print("Accuracy:", model.score(X_test, y_test))
```

2. 多项式朴素贝叶斯实验（文本数据）

```
from sklearn.datasets import fetch_20newsgroups
from sklearn.pipeline import make_pipeline

# 加载数据
categories = ['sci.space', 'rec.autos']
newsgroups = fetch_20newsgroups(subset='train', categories=categories)
X, y = newsgroups.data, newsgroups.target

# 构建流水线（TF-IDF + 分类器）
pipeline = make_pipeline(
    TfidfVectorizer(stop_words='english'),
    MultinomialNB(alpha=0.1)
)
pipeline.fit(X, y)
```

四、实验要求

必做任务

1. 对鸢尾花数据集分别使用高斯和多项式模型，解释为何多项式模型不适用
2. 在文本分类任务中，比较TfidfVectorizer与CountVectorizer的效果差异
3. 修改alpha参数，绘制准确率随平滑系数变化的曲线

扩展任务

1. 手动实现TF-IDF计算函数，并与scikit-learn结果对比
 2. 在新闻数据集上增加二元语法（bigram）特征，观察模型性能变化
-

五、思考题

1. 若某特征在训练集中未出现（如文本中的新词），高斯和多项式模型分别如何处理？
2. TF-IDF的IDF公式中为何要加1？若不加会导致什么问题？
3. 高斯朴素贝叶斯是否需要对特征进行标准化？为什么？